

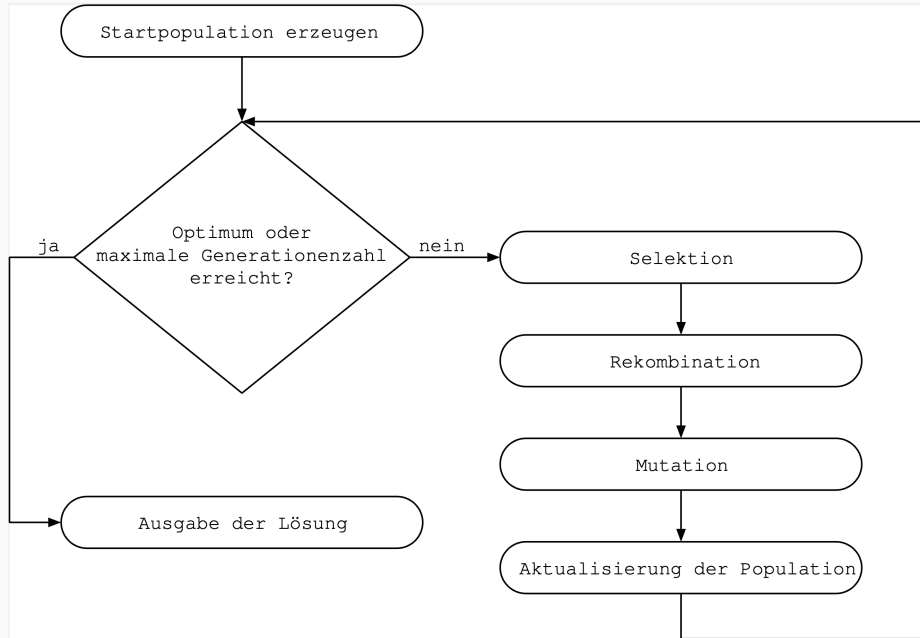
# Modellierung mit Genetischen Algorithmen

---

Carsten Gips (HSBI)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

# EA – Allgemeiner Ablauf



- Binäre Lösungsrepräsentation (Bitstring):  $\mathbf{g} = (g_1, \dots, g_m) \in \{0, 1\}^m$ 
  - String gliedert sich in  $n$  Elemente (mit  $n \leq m$ )  
 $\Rightarrow$  jedes Segment entspricht einer Problemvariablen
  - Dekodierungsfunktion  $\Gamma : \{0, 1\}^m \rightarrow \mathbb{R}^n$
- Fitnessfunktion  $\Phi$  ordnet jedem Individuum  $\mathbf{g}_i$  eine reelle Zahl zu:

$$\Phi(\mathbf{g}_i) = F(\Gamma(\mathbf{g}_i)) - w \cdot \sum_j (Z_j(\Gamma(\mathbf{g}_i)))^2$$

- Zielfunktion  $F$ : wie sehr genügt ein Individuum bereits dem Optimierungsproblem
- Strafterme  $Z_j$ : Anreicherung der Optimierung mit weiteren Informationen
- Gewichte  $w$ : statisch oder dynamisch (Abkühlen)

## Selektion: Erstelle Matingpool mit $\mu$ Individuen

- Fitnessproportionale Selektion (*Roulette Wheel Selection*):  
Auswahlwahrscheinlichkeit für Individuum  $\mathbf{g}_k$ :

$$p_{sel}(\mathbf{g}_k) = \frac{\Phi(\mathbf{g}_k)}{\sum_j \Phi(\mathbf{g}_j)}$$

=> Voraussetzung: positive Fitnesswerte

- Turnier-Selektion (*Tournament Selection*):
  - Turniergröße  $\xi$
  - Turnier: ziehe  $\xi$  Individuen gleichverteilt (mit Zurücklegen!) und kopiere fittestes Individuum in den Matingpool
  - Führe  $\mu$  Turniere durch

# Crossover: Erzeuge zwei Nachkommen aus zwei Eltern

Festlegung der Crossover-Wahrscheinlichkeit  $p_{cross}$  (typisch:  $p_{cross} \geq 0.6$ )

1. Selektiere Eltern  $\mathbf{g}_a$  und  $\mathbf{g}_b$  **gleichverteilt** aus Matingpool
2. Zufallsexperiment:
  - mit  $1 - p_{cross}$ : Kinder identisch zu Eltern (kein Crossover)
  - mit  $p_{cross}$ : Crossover mit  $\mathbf{g}_a$  und  $\mathbf{g}_b$ 
    - Ziehe  $i$  gleichverteilt mit  $1 < i < m$
    - Kinder aus  $\mathbf{g}_a$  und  $\mathbf{g}_b$  zusammenbauen:

$$\mathbf{g}_c = (g_{a,1}, \dots, g_{a,i}, g_{b,i+1}, \dots, g_{b,m})$$

und

$$\mathbf{g}_d = (g_{b,1}, \dots, g_{b,i}, g_{a,i+1}, \dots, g_{a,m})$$

3. Gehe zu Schritt 1, bis insg.  $\mu$  Nachkommen

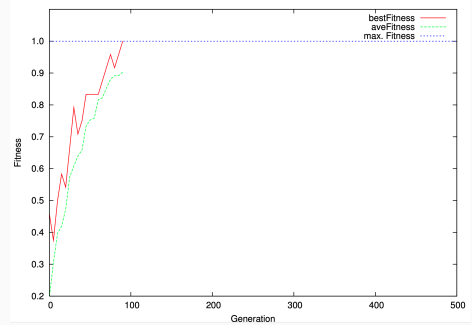

*Anmerkung:* Die Eltern werden jeweils in die Ausgangsmenge zurückgelegt.

- Mutationswahrscheinlichkeit  $p_{mut}$   
(typische Werte:  $p_{mut} = 0.01$  oder  $p_{mut} = 0.001$ )
- Für alle Individuen:
  - Mutiere jedes Gen eines Individuums mit  $p_{mut}$ :

$$g_i^{(t+1)} = \begin{cases} \neg g_i^{(t)} & \text{falls } \chi_i \leq p_{mut} \\ g_i^{(t)} & \text{sonst} \end{cases}$$

$\Rightarrow \chi_i$  gleichverteilte Zufallsvariable (Intervall  $[0, 1]$ ), für jedes Bit  $g_i$  neu bestimmen

# Typische Läufe



- Populationsgröße  $\mu = 15$
- Anzahl Nachfahren  $\lambda = 100$
- Abbruch nach  $maxGen = 200$  Generationen

Lokale Suchverfahren: Nur das Ergebnis zählt!

- Evolutionäre Algorithmen:
  - Begriffe: Individuum, Population, Kodierung
  - Operationen: Selektion, Rekombination, Mutation
  - Bewertung mit Fitnessfunktion



# LICENSE



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.